

İstatistiksel Makine Çevirisi Proje Raporu

1. Proje Özeti ve Amacım

Bu projede, İngilizce-Türkçe dil çifti arasında çeviri yapabilen bir İstatistiksel Makine Çevirisi (SMT) sistemini sıfırdan geliştirdim. Hazır çeviri API'ları veya kütüphaneleri kullanmak yerine, çeviri mantığını oluşturan IBM Modellerini ve Expectation-Maximization (EM) algoritmasını Python ile kendim kodladım.

Amacım, bir makinenin iki dil arasındaki kelime eşleşmelerini ve hizalamalarını (alignment) istatistiksel olarak nasıl öğrendiğini göstermektir.

2. Veri Seti Üzerinde Yaptığım Çalışmalar

Veri seti olarak OPUS projesinden Tatoeba (İngilizce-Türkçe) verilerini kullandım.

Bu aşamada gerçekleştirdiğim işlemler:

- * Veri Hattı (Pipeline) Kurulumu: Kütüphane uyumsuzluklarını aşmak için veriyi doğrudan kaynaktan indiren ve işleyen özel bir script yazdım.
- * Veri Temizliği: 30.000 cümle çiftini noktalama işaretlerinden arındırdım ve küçük harfe (lowercase) çevirdim.
- * Eğitim/Test Ayrımı: Modelin ezberlemesini önlemek için verinin %90'ını eğitime, %10'unu test aşamasına ayırdım.

3. Geliştirdiğim Algoritmalar

Proje kapsamında iki temel olasılık modelini Python sınıf yapısı (Class) içinde implemente ettim:

A) IBM Model 1 (Kelime Çevirisi):

Cümle yapısına bakmaksızın, sadece hangi kelimenin hangi kelimeyle eşleşebileceğini hesaplayan olasılık tablosunu (Lexical Translation Probabilities) oluşturdum.

B) IBM Model 2 (Hizalama/Alignment):

Model 1'in üzerine, kelimelerin cümle içindeki konumlarını da dikkate alan bir yapı ekledim. Böylece modelim, İngilizce'deki 1. kelimenin Türkçe'de genellikle cümlenin sonunda yer aldığını öğrenmeye başladı.

4. Elde Ettiğim Sonuçlar

30.000 cümlelik veri seti üzerindeki eğitim sonucunda şu bulgulara ulaştım:

- * Başarı Skoru (BLEU-1): Yaklaşık 0.30 skor elde ettim. Bu skor, modelimin kelime eşleştirmelerini (Örn: 'Apple' -> 'Elma') başarıyla öğrendiğini kanıtlamaktadır.
- * Görselleştirme: Eğitim sonrası oluşturduğum 'Isı Haritası' (Heatmap) ile modelin kelime hizalamalarını görselleştirdim ve matematiksel olarak doğru eşleşmeler yaptığını doğruladım.

İstatistiksel Makine Çevirisi Proje Raporu

Sonuç olarak; gramer yapısını tam kuramasa da (Language Model eksikliği nedeniyle), modelim kelime anlamlarını ve istatistiksel ilişkileri başarıyla öğrenmiştir.

bavsimus - Ocak 2026